

تمرین ششم سوم درس یادگیری ماشین

سؤال اول

۱. ۲۵ نمره) صحیح و غلط بودن هر مورد را مشخص کنید. در موارد (الف)، (و) و (ی) نیز با استدلال پاسخ دهید.

الف) می‌دانیم که 2^n تابع boolean متمایز بر روی n ورودی وجود دارند. در نتیجه برای ۲ ورودی، ۱۶ تابع boolean متمایز وجود دارد. چند تا از این ۱۶ تابع را می‌توان توسط یک perceptron نشان داد؟ چرا؟

ب) تابع فعال‌سازی \tanh به دلیل صفرمحور بودن، برخلاف تابع sigmoid مشکل ناپدیدکردن گرادیان را ندارد.

ج) هر تابع منطقی را می‌توان با یک شبکه دولایه (یک لایه مخفی) و یک تابع فعال‌سازی ReLU نمایش داد.

د) افزایش عمق و عرض یک شبکه عصبی همیشه عملکرد آن را بهبود می‌بخشد.

ه) یک شبکه عصبی سطحی و بسیار پهن می‌تواند همیشه به اندازه یک شبکه عصبی عمیق هر تابعی را به صورت کارآمد تقریب بزند.

و) مشکل ناپدیدشدن گرادیان در آموزش شبکه‌های عصبی چیست و چگونه توابع فعال‌سازی مانند ReLU به کاهش آن کمک می‌کنند؟

ز) (SGD) Stochastic Gradient Descent با اندازه batch کوچک به دلیل فرکانس بالای بهروزرسانی تضمین می‌کند سریع‌تر از mini-batch gradient descent شود.

ی) با استفاده از Stochastic Gradient Descent با ممان اول، از نقطه اولیه $x = -2/8$ ، با نرخ یادگیری $\gamma = 0.05$ ، ضریب ممان $\mu = 0.05$ و تعداد تکرار $i = 2$ کمینه کنید. مقادیر g_i, m_i, x_i و y_i و محاسبات هر مرحله باید ارائه شوند. (منظور از g_i گرادیان در مرحله i و m_i مقدار ممان در مرحله i می‌باشد) نیازی به اصلاح بایاس نیست. $y = 0.1x^3 - 0.8x^2 - 2x^1 - 0.1$

الف) یک perceptron تنها می‌تواند داده‌های متعاقبی را در صورت خوبی جدا نماید. دو ورودی چهار حالت می‌توانند باشند بخصوص $(0,0), (0,1), (1,0)$ و $(1,1)$ نیز یک تابع XOR، XNOR را با یک perceptron نشان داد. بنابراین تنها ۱۶ تابع از ۲۵ تابع را می‌توان با استفاده از یک perceptron نشان داد.

ب) نادرست. تابع $\tanh(x)$ در مقادیر زیاد و کم $\pm \infty$ طایی نماید. بسیار کمی باشد و در نتیجه دارای مشکل نایدیدگی است. گرادیان خواهد بود.

ج) درست. با توجه به قضیه Universal Approximation Theorem می‌دانیم که با استفاده از یک شبکه عصبی که طایی یک لایه hidden ی باشد که دارای تابع activation غیرخطی می‌باشد می‌توان هر تابع پیوسته‌ای را تقریب نمود. به طور ممکن تابع منطقی را می‌توان به صورت مع تعدادی ضرب (Sum of Products) نوشت.

۵) نادرست. این کار نزدیک باعث overfitting افزایش دقت می‌شود و نکن است باعث ایجاد مواردی مجهول (train data) باشد. همین بسته به نوع activation function تواند باعث وجود آمدن vanishing gradients شود.

۶) درست. می‌توان سبکهای عصبی سطحی و یعنی با تعداد زیادی نورون را استفاده کرد تا هر تابع را تقریب زد؛ اما در این نسبت به سبکهای عصبی سطحی تعداد زیادی نورون نیازداریم زیرا سبکهای عصبی عینی نجیب‌گی همچنان تابع را با افزایش عمق بخوبتر تقریب می‌زنند اما سبکهای عصبی سطحی با افزایش عمق را بخوبی تقریب نمی‌زنند.

۷) در صورت وجود مسئلک نایپیدیشن گرادیان، برای تقویت فن‌های update کنیم و در نتیجه دقت عمل افزایشی خواهد بود.

تابع فعال سازی $\text{ReLU}(\alpha)$ به صورت $\max(0, \alpha)$ تعریف می‌شود و بنابراین مسئله آن به صورت تقریب می‌شود و با قوه به اینه که در مورد باقاعدگی ثابت گرادیان، به مسئلک نایپیدیشن گرادیان بخواهیم خورد.

۸) در SGD با μ بارانی تعداد نقاط تقریبی به روزرسانی صورت می‌پید و در نتیجه مرکاش بالاتری در به روزرسانی مقادیر خواهیم داشت که convergence سریع‌تری را نسبت به mini-batch gradient descent دارد؛ اما این اوضاع در نزدیکی نقطه (نقطه optima) ممکن است (این معنا نه دارای تغیرات جزئی در آن نقاطی باشد).

$$\text{SGD with momentum update rule} \quad \begin{cases} m_{t+1} = \mu m_t + (1-\mu) \nabla J(x) \\ x_{t+1} = x_t - \gamma m_{t+1} \end{cases} \quad (5)$$

$$\mu = 0.7, \gamma = 0.05, x_0 = -2.8, m_0 = 0, \nabla J(x) = \frac{\partial}{\partial x} [0.3x^4 - 0.1x^3 - 2x^2 - 0.8x] = 1.2x^3 - 0.3x^2 - 4x - 0.8$$

$$i=1: \quad g_1 = 1.2x_0^3 - 0.3x_0^2 - 4x_0 - 0.8 = -18.2944 \rightarrow m_1 = 0.7m_0 + 0.3g_1 = -5.48832 \\ \rightarrow x_1 = x_0 - 0.05m_1 = -2.525584 \rightarrow y_1 = 0.3x_1^4 - 0.1x_1^3 - 2x_1^2 - 0.8x_1 = 3.08014$$

$$i=2: \quad g_2 = 1.2x_1^3 - 0.3x_1^2 - 4x_1 - 0.8 = -11.94279 \rightarrow m_2 = 0.7m_1 + 0.3g_2 = -7.42466 \\ \rightarrow x_2 = x_1 - 0.05m_2 = -2.15435 \rightarrow y_2 = 0.3x_2^4 - 0.1x_2^3 - 2x_2^2 - 0.8x_2 = -0.09679$$

سؤال دهم:

۱۵ نمره) تابع $y = f(x_1, x_2, x_3)$ به صورت زیر تعریف شده است:

$$y = 6z_1 + 2z_2 + 4$$

$$z_1 = \exp\left(-\frac{\max\{|x_1 - 3|, |x_2 - 5|, |x_3 + 2|\}^2}{4}\right)$$

$$z_2 = \begin{cases} 0, & \text{if } \sqrt{(x_1 + 3)^2 + (x_3 - 4)^2} > 4 \\ 1, & \text{otherwise} \end{cases}$$


الف) شبکه عصبی تولیدکننده این تابع را با در نظر گرفتن مدل نورون عمومی رسم کنید. برای هر نورون، تابع ورودی شبکه، تابع فعالسازی و تابع خروجی را بر حسب وزن‌های ورودی و مقادیر پارامتری مشخص کنید. وزن‌ها و مقادیر آستانه را تعیین کنید. (نکته: جواب این سؤال یکتا نیست)

ب) با یک شبکه عصبی متخلک از نورون‌های عمومی، تابع زیر را بسازید (فرض کنید f_{net} فقط می‌تواند جمع وزن‌دار ورودی‌ها باشد و f_{out} هم فقط می‌تواند تابع همانی باشد).

$$f(x_1, x_2, x_3) = \max\{x_3, x_1^{x_2}\}$$

الف) ابتدا تغیرها و تابع کوچک ترمی سازیم:





در هر نورون تابع activation (را نوشته ام)



$$\max\{x_1, x_2\} = \text{ReLU}(x_1 - x_2) + x_2 \rightsquigarrow \max\{x_1, x_2, x_3\} = \max\{x_1, \max\{x_2, x_3\}\} = \max\{x_1, \text{ReLU}(x_2 - x_3) + x_3\}$$


$$= \text{ReLU}(x_1 - \text{ReLU}(x_2 - x_3) - x_3) + \text{ReLU}(x_2 - x_3) + x_3$$

$\rightsquigarrow \max\{x_1, x_2, x_3\} :$




حال با استفاده از Network رایی سازم:

Creating \underline{z}_1 using networks no. 1, 2, 3 and 4:




Creating \underline{z}_2 using network no. 3, 5:



در اینجا ناجع 1-ReLU ب صورت نراس است:

$$1-\text{ReLU}(x) = 1 - \begin{cases} 0 & \text{if } x \leq 0 \\ 1 & \text{if } x > 0 \end{cases} = \begin{cases} 1 & \text{if } x \leq 0 \\ 0 & \text{if } x > 0 \end{cases}$$


حال که \underline{z}_1 و \underline{z}_2 را به دست آوردم، می‌توانیم y را هم به دست آوریم:



ب) در بعضی ممل دیدیم که $\underline{\max\{x_1, x_2\}} = \text{ReLU}(x_1 - x_2) + x_2$. حال عبارت $\underline{x_1^{x_2}}$ را به دست می‌آوریم:


$$x_1^{x_2} = (x_1)^{x_2} = (e^{\ln(x_1)})^{x_2} = e^{x_2 \ln(x_1)}, x_2 \ln(x_1) = e^{\ln(x_2)} e^{\ln(\ln(x_1))} = \exp[\ln(x_2) + \ln(\ln(x_1))]$$

حال سلسله عصبی رایی سازم:



حال سبله عصبی کل رای سانیم:

$$f(x_1, x_2, x_3) = \max\{x_3, x_1^{x_2}\} = \text{ReLU}(x_1^{x_2} - x_3) + x_3$$



سؤال سوم:

۳. ۱۵ نمره) فرض کنید که یک شبکه عصبی دو لایه داریم که به صورت زیر تعریف شده است: توجه کنید که یک نمونه ورودی منفرد است و شکل آن $D_x \times 1$ است. همچنین $y^{(i)}$ یک برچسب خروجی است و یک اسکالر محسوب می‌شود. در دیتابست ما m نمونه وجود دارد. ما از تعداد D_{a_1} نód در لایه مخفی استفاده می‌کنیم، بنابراین شکل z_1 برابر $1 \times D_{a_1}$ است.

۱. ابعاد W_1 , b_1 و W_2 , b_2 چیست؟ اگر بخواهیم شبکه را روی چندین نمونه vectorize کنیم، شکل وزن‌ها و بایاس‌ها چه تغییری خواهد کرد؟ اگر بخواهیم شبکه را روی چندین نمونه ورودی vectorize کنیم، شکل‌های X و Y چگونه خواهد بود؟

۲. مقدار $\frac{\partial J}{\partial y^{(i)}}$ چیست؟ این مقدار را $\delta^{(i)}$ نام‌گذاری کنید. با استفاده از این نتیجه، مقدار $\frac{\partial J}{\partial \hat{y}^{(i)}}$ چیست؟

۳. مقدار $\frac{\partial \hat{y}^{(i)}}{\partial z_1}$ چیست؟ این مقدار را $\delta^{(i)}$ نام‌گذاری کنید.

۴. مقدار $\frac{\partial z_1}{\partial a_1}$ چیست؟ این مقدار را $\delta^{(i)}$ بنامید.

۵. مقدار $\frac{\partial a_1}{\partial z_0}$ چیست؟ این مقدار را $\delta^{(i)}$ بنامید.

۶. مقدار $\frac{\partial z_0}{\partial W_1}$ چیست؟ این مقدار را $\delta^{(i)}$ بنامید.

۷. مقدار $\frac{\partial J}{\partial W_1}$ چیست؟ می‌توانید از نتایج قبلی استفاده کنید.

$$z_1 = W_1 x^{(i)} + b_1$$

$$a_1 = \text{ReLU}(z_1)$$

$$z_2 = W_2 a_1 + b_2$$

$$\hat{y}^{(i)} = \sigma(z_2)$$

$$L^{(i)} = y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

$$J = -\frac{1}{m} \sum_{i=1}^m L^{(i)}$$

$$z_1 = W_1 x^{(i)} + b_1, \rightarrow \text{shape}(z_1) = \text{shape}(W_1 x^{(i)} + b_1) = D_{a_1} \times 1 \rightarrow \text{shape}(b_1) = D_{a_1} \times 1 \quad .1$$

$$\rightarrow \text{shape}(W_1 x^{(i)}) = D_{a_1} \times 1, \text{shape}(x^{(i)}) = D_x \times 1 \rightarrow \text{shape}(W_1) = D_{a_1} \times D_x$$

$$a_1 = \text{ReLU}(z_1) \rightarrow \text{shape}(a_1) = \text{shape}(z_1) = D_{a_1} \times 1$$

$$\hat{y}^{(i)} = \sigma(z_2) \rightarrow \text{shape}(z_2) = \text{shape}(\hat{y}^{(i)}) = 1 \times 1 \quad (\hat{y}^{(i)} \text{ is a scalar})$$

$$z_2 = W_2 a_1 + b_2 \rightarrow \text{shape}(W_2 a_1 + b_2) = \text{shape}(z_2) = 1 \times 1 \rightarrow \text{shape}(b_2) = 1 \times 1$$

$$\rightarrow \text{shape}(W_2 a_1) = 1 \times 1, \text{shape}(a_1) = D_{a_1} \times 1 \rightarrow \text{shape}(W_2) = 1 \times D_{a_1}$$

فرض کنید در حال ساخت شبکه عصبی برداری N داده هستیم.

$$z_1 = W_1 X + b_1, \text{shape}(X) = D_x \times N \quad W_1 \text{'s shape is independent from } X \text{'s second dimension} \rightarrow \text{shape}(W_1) = D_{a_1} \times D_x$$

$$\rightarrow \text{shape}(z_1) = \text{shape}(W_1 X + b_1) = \text{shape}(W_1 X) = D_{a_1} \times N, \text{shape}(z_1) = \text{shape}(b_1)$$

$$\rightarrow \text{shape}(b_1) = D_{a_1} \times N, \text{shape}(a_1) = \text{shape}(z_1) = D_{a_1} \times N, \text{shape}(z_2) = 1 \times N \quad (z_2 \text{ is a scalar})$$

$$W_2 \text{'s shape is independent from } a_1 \text{'s second dimension} \rightarrow \text{shape}(W_2) = 1 \times D_{a_1}, \text{shape}(b_2) = \text{shape}(z_2)$$

$$\rightarrow \text{shape}(b_2) = 1 \times N \quad \text{shape}(\hat{Y}) = \text{shape}(z_2) \rightarrow \text{shape}(\hat{Y}) = 1 \times N$$

.2

$$\begin{aligned} \delta_1^{(i)} &= \frac{\partial J}{\partial \hat{y}^{(i)}} = \frac{\partial}{\partial \hat{y}^{(i)}} \left[-\frac{1}{m} \sum_{j=1}^m (y^{(j)} \log(\hat{y}^{(j)}) + (1-y^{(j)}) \log(1-\hat{y}^{(j)})) \right] = -\frac{1}{m} \sum_{j=1}^m \frac{\partial}{\partial \hat{y}^{(i)}} [y^{(j)} \log(\hat{y}^{(j)}) + (1-y^{(j)}) \log(1-\hat{y}^{(j)})] \\ &= -\frac{1}{m} \frac{\partial}{\partial \hat{y}^{(i)}} [y^{(i)} \log(\hat{y}^{(i)}) + (1-y^{(i)}) \log(1-\hat{y}^{(i)})] = -\frac{1}{m} \left[\frac{y^{(i)}}{\hat{y}^{(i)}} - \frac{1-y^{(i)}}{1-\hat{y}^{(i)}} \right] \\ &\rightarrow \delta_1^{(i)} = \frac{\partial J}{\partial \hat{y}^{(i)}} = -\frac{1}{m} \left(\frac{y^{(i)}}{\hat{y}^{(i)}} - \frac{1-y^{(i)}}{1-\hat{y}^{(i)}} \right) \end{aligned}$$

$$\rightarrow \frac{\partial J}{\partial \hat{Y}} = \begin{bmatrix} \frac{\partial J}{\partial \hat{y}^{(1)}} & \frac{\partial J}{\partial \hat{y}^{(2)}} & \dots & \frac{\partial J}{\partial \hat{y}^{(m)}} \end{bmatrix} \rightarrow \frac{\partial J}{\partial \hat{Y}} = -\frac{1}{m} \begin{bmatrix} \frac{y^{(1)}}{\hat{y}^{(1)}} - \frac{1-y^{(1)}}{1-\hat{y}^{(1)}} & \dots & \frac{y^{(m)}}{\hat{y}^{(m)}} - \frac{1-y^{(m)}}{1-\hat{y}^{(m)}} \end{bmatrix}$$

.3

$$\delta_2^{(i)} = \frac{\partial \hat{y}^{(i)}}{\partial z_2} = \frac{\partial}{\partial z_2} \sigma(z_2) = \sigma(z_2)(1-\sigma(z_2)) \rightarrow \delta_2^{(i)} = \frac{\partial \hat{y}^{(i)}}{\partial z_2} = \sigma(z_2)(1-\sigma(z_2)) = \hat{y}^{(i)}(1-\hat{y}^{(i)})$$

.4

$$\delta_3^{(i)} = \frac{\partial z_2}{\partial a_1} = \frac{\partial}{\partial a_1} [W_2 a_1 + b_2] = W_2 \rightarrow \delta_3^{(i)} = \frac{\partial z_2}{\partial a_1} = W_2$$

$$\delta_4^{(i)} = \frac{\partial a_1}{\partial z_1} = \frac{\partial}{\partial z_1} \text{ReLU}(z_1) = \begin{cases} \frac{\partial z_1}{\partial z_1} = 1 & \text{if } z_1 > 0 \\ 0 & \text{o.w.} \end{cases} \rightarrow \delta_4^{(i)} = \frac{\partial a_1}{\partial z_1} = \begin{cases} 1 & \text{if } z_1 > 0 \\ 0 & \text{o.w.} \end{cases}$$

.6

$$\delta_5^{(i)} = \frac{\partial z_1}{\partial w_1} = \frac{\partial}{\partial w_1} [W_1 x^{(i)} + b_1] = x^{(i)\top} \rightarrow \delta_5^{(i)} = \frac{\partial z_1}{\partial w_1} = x^{(i)}$$

.7

$$\frac{\partial J}{\partial w_1} = \frac{\partial J}{\partial \hat{y}^{(i)}} \frac{\partial \hat{y}^{(i)}}{\partial z_2} \frac{\partial z_2}{\partial a_1} \frac{\partial a_1}{\partial z_1} \frac{\partial z_1}{\partial w_1} = \delta_1^{(i)} \delta_2^{(i)} \delta_3^{(i)} \delta_4^{(i)} \delta_5^{(i)}$$

$$= -\frac{1}{m} \left(\frac{y^{(i)}}{\hat{y}^{(i)}} - \frac{1-y^{(i)}}{1-\hat{y}^{(i)}} \right) \hat{y}^{(i)} (1-\hat{y}^{(i)}) W_2 x^{(i)} \delta_4^{(i)} = -\frac{1}{m} [y^{(i)}(1-\hat{y}^{(i)}) - \hat{y}^{(i)}(1-y^{(i)})] W_2 x^{(i)} \delta_4^{(i)}$$

$$\rightarrow \frac{\partial J}{\partial w_1} = \begin{cases} \frac{\hat{y}^{(i)}(1-y^{(i)}) - y^{(i)}(1-\hat{y}^{(i)})}{m} W_2 x^{(i)} & \text{if } W_2 x^{(i)} + b_1 > 0 \\ 0 & \text{o.w.} \end{cases}$$

سوال چهارم:

۴. (۳۰ نمره) یک شبکه عصبی feedforward با معماری زیر را در نظر بگیرید:

وزن‌ها و بایاس‌های اولیه شبکه به صورت زیر است:
وزن‌ها و بایاس‌ها از لایه ورودی به لایه مخفی ۱ (لایه ۱):

$$W^{(1)} = \begin{bmatrix} a & -a \\ b & a \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} \cdot \\ \cdot \end{bmatrix}$$

وزن‌ها و بایاس‌ها از لایه مخفی ۱ به لایه مخفی ۲ (لایه ۲):

$$W^{(2)} = \begin{bmatrix} a & b \\ -b & -a \end{bmatrix}, \quad b^{(2)} = \begin{bmatrix} \cdot \\ \cdot \end{bmatrix}$$

وزن‌ها و بایاس‌ها از لایه مخفی ۲ به لایه مخفی ۳ (لایه ۳):


$$W^{(3)} = \begin{bmatrix} a & -b \\ -a & b \end{bmatrix}, \quad b^{(3)} = \begin{bmatrix} \cdot \\ \cdot \end{bmatrix}$$

وزن‌ها و بایاس‌ها از لایه مخفی ۳ به لایه خروجی (لایه ۴):

$$W^{(4)} = \begin{bmatrix} a & -b \\ 0.5a & a \end{bmatrix}, \quad b^{(4)} = \begin{bmatrix} \cdot \\ \cdot \end{bmatrix}$$

بردار ورودی x و خروجی هدف t به صورت زیر است:

$$x = \begin{bmatrix} \cdot \\ \cdot \\ \cdot \end{bmatrix}, \quad t = \begin{bmatrix} \cdot \\ \cdot \\ \cdot \end{bmatrix}$$



لایه ورودی: ۲ نورون

لایه مخفی ۱: ۲ نورون، با استفاده از تابع فعالسازی Sigmoid

لایه مخفی ۲: ۲ نورون، با استفاده از تابع فعالسازی ReLU

لایه مخفی ۳: ۲ نورون، با استفاده از تابع فعالسازی Softmax

لایه خروجی: ۲ نورون، با استفاده از تابع فعالسازی Identity

با استفاده از نخ یادگیری (η)، یک بار فرآیند backpropagation را انجام دهید تا وزن‌ها و بایاس‌های شبکه بهروزرسانی شوند. از تابع فعالسازی زیر در هر لایه استفاده کنید:

لایه ۱: $\sigma(x) = \frac{1}{1 + e^{-x}}$: (Sigmoid)

لایه ۲: $\text{ReLU}(x) = \max(\cdot, x)$: (ReLU)

لایه ۳: $\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$: (Softmax)

لایه ۴: $f(x) = x$: (Identity)

فرض کنید تابع خطا به صورت میانگین مربعات (MSE) تعریف شده است:

$$E = \frac{1}{\gamma} \sum_{k=1}^{\gamma} (a_k^{(4)} - t_k)^2$$

که در آن $a^{(4)}$ خروجی شبکه است.

الف) وردی را از همای لایه‌های گذراش تا انجام سود:

$$Z^{(1)} = W^{(1)}_x + b^{(1)} = \begin{bmatrix} a & -a \\ b & a \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} a \\ b \end{bmatrix} \xrightarrow{a^{(1)} = \sigma(Z^{(1)})} \begin{bmatrix} \frac{1}{1+e^{-a}} \\ \frac{1}{1+e^{-b}} \end{bmatrix}$$

$$\xrightarrow{Z^{(2)} = W^{(2)} a^{(1)} + b^{(2)} = \begin{bmatrix} a & b \\ -b & -a \end{bmatrix} \begin{bmatrix} \frac{1}{1+e^{-a}} \\ \frac{1}{1+e^{-b}} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{a}{1+e^{-a}} + \frac{b}{1+e^{-b}} \\ \frac{-b}{1+e^{-a}} - \frac{a}{1+e^{-b}} \end{bmatrix}}$$

$$\xrightarrow{a^{(2)} = \text{ReLU}(Z^{(2)}) = \begin{cases} \max(0, \frac{a}{1+e^{-a}} + \frac{b}{1+e^{-b}}) \\ \max(0, \frac{-b}{1+e^{-a}} - \frac{a}{1+e^{-b}}) \end{cases} = \begin{bmatrix} \frac{a}{1+e^{-a}} + \frac{b}{1+e^{-b}} \\ 0 \end{bmatrix}}$$

$$\tilde{z}^{(3)} = W^{(3)} a^{(2)} + b^{(3)} = \begin{bmatrix} a & -b \\ -a & b \end{bmatrix} \begin{bmatrix} \frac{a}{1+e^{-a}} + \frac{b}{1+e^{-b}} \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}} \\ -\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}} \end{bmatrix}$$

$$a^{(3)} = \text{softmax}(\tilde{z}^{(3)}) = \frac{1}{\exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) + \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right)} \begin{bmatrix} \exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) \\ \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right) \end{bmatrix}$$

$$\begin{aligned} \tilde{z}^{(4)} &= W^{(4)} a^{(3)} + b^{(4)} = \begin{bmatrix} a & -b \\ 0.5a & a \end{bmatrix} \begin{bmatrix} \exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) \\ \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right) \end{bmatrix} \\ &\quad + \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ &= \frac{1}{\exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) + \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right)} \begin{bmatrix} a \cdot \exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) - b \cdot \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right) \\ \frac{a}{2} \exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) + a \cdot \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right) \end{bmatrix} \end{aligned}$$

$$a^{(4)} = \text{Identity}(\tilde{z}^{(4)}) = \tilde{z}^{(4)}$$

$$= \frac{1}{\exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) + \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right)} \begin{bmatrix} a \cdot \exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) - b \cdot \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right) \\ \frac{a}{2} \exp\left(\frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}\right) + a \cdot \exp\left(-\frac{a^2}{1+e^{-a}} - \frac{ab}{1+e^{-b}}\right) \end{bmatrix}$$

$$c := \frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}$$

$$E = \frac{1}{2} \sum_{k=1}^2 (a_k^{(4)} - t_k)^2 = \frac{1}{2} \left[(a_1^{(4)} - t_1)^2 + (a_2^{(4)} - t_2)^2 \right] = \frac{1}{2} \left[a_1^{(4)2} + (a_2^{(4)} - 1)^2 \right]$$

$$= \frac{1}{2} \frac{1}{(e^c + e^{-c})^2} \left[(ae^c - be^{-c})^2 + \left(\frac{a}{2}e^c + ae^{-c} - 1\right)^2 \right]$$

$$= \frac{1}{2(e^{2c} + e^{-2c} + 2)} \left[a^2 e^{2c} + b^2 e^{-2c} - 2ab + \frac{a^2}{4} e^{2c} + a^2 e^{-2c} + a^2 + 1 - ae^c - 2ae^{-c} \right]$$

$$E = \frac{1}{2(e^{2c} + e^{-2c} + 2)} \left[\frac{5}{4} a^2 e^{2c} + (a^2 + b^2) e^{-2c} - (e^c + 2e^{-c}) a + (a^2 - 2ab + 1) \right], \quad c = \frac{a^2}{1+e^{-a}} + \frac{ab}{1+e^{-b}}$$

ج) بازندهی با آنکار آرس خسروی

$$E = \frac{1}{2} \|a^{(4)} - t\|_2^2 \quad \rightarrow \quad \frac{\partial E}{\partial a^{(4)}} = a^{(4)} - t$$

$$\rightarrow \frac{\partial E}{\partial w^{(4)}} = \frac{\partial E}{\partial a^{(4)}} \frac{\partial a^{(4)}}{\partial w^{(4)}} = \frac{\partial E}{\partial a^{(4)}} \frac{\partial a^{(4)}}{\partial z^{(4)}} \frac{\partial z^{(4)}}{\partial w^{(4)}} = (a^{(4)} - t) a^{(3)T}$$

$$, \frac{\partial E}{\partial b^{(4)}} = \frac{\partial E}{\partial a^{(4)}} \frac{\partial a^{(4)}}{\partial z^{(4)}} \frac{\partial z^{(4)}}{\partial b^{(4)}} = a^{(4)} - t$$

$$\rightarrow \frac{\partial E}{\partial a^{(3)}} = \frac{\partial E}{\partial a^{(4)}} \frac{\partial a^{(4)}}{\partial a^{(3)}} = \frac{\partial E}{\partial a^{(4)}} \frac{\partial a^{(4)}}{\partial z^{(4)}} \frac{\partial z^{(4)}}{\partial a^{(3)}} = W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial z^{(3)}} = \frac{\partial E}{\partial a^{(3)}} \frac{\partial a^{(3)}}{\partial z^{(3)}} = (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial w^{(3)}} = \frac{\partial E}{\partial z^{(3)}} \frac{\partial z^{(3)}}{\partial w^{(3)}} = (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t) a^{(2)T}$$

$$, \frac{\partial E}{\partial b^{(3)}} = \frac{\partial E}{\partial z^{(3)}} \frac{\partial z^{(3)}}{\partial b^{(3)}} = (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial a^{(2)}} = \frac{\partial E}{\partial z^{(3)}} \frac{\partial z^{(3)}}{\partial a^{(2)}} = W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial z^{(2)}} = \frac{\partial E}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial w^{(2)}} = \frac{\partial E}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial w^{(2)}} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t) a^{(1)T}$$

$$, \frac{\partial E}{\partial b^{(2)}} = \frac{\partial E}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial b^{(2)}} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial a^{(1)}} = \frac{\partial E}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} = W^{(2)T} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial z^{(1)}} = \frac{\partial E}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} = \text{diag}(a^{(1)}(1-a^{(1)})) W^{(2)T} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

$$\rightarrow \frac{\partial E}{\partial w^{(1)}} = \frac{\partial E}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial w^{(1)}} = \text{diag}(a^{(1)}(1-a^{(1)})) W^{(2)T} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t) a^{(1)T}$$

$$, \frac{\partial E}{\partial b^{(1)}} = \frac{\partial E}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial b^{(1)}} = \text{diag}(a^{(1)}(1-a^{(1)})) W^{(2)T} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} W^{(3)T} (\text{diag}(a^{(3)}) - a^{(3)} a^{(3)T}) W^{(4)T} (a^{(4)} - t)$$

۵) برای بروزرسانی صفت‌گاهیست که هر یارا متر را با استفاده از مستقیم در بالا بدست آوردم، کاهش دهم:

$$w^{(1)(t+1)} = w^{(1)(t)} - \eta \left(\frac{\partial E}{\partial w^{(1)}} \right)^{(t)}, \quad b^{(1)(t+1)} = b^{(1)(t)} - \eta \left(\frac{\partial E}{\partial b^{(1)}} \right)^{(t)}$$


$$w^{(2)(t+1)} = w^{(2)(t)} - \eta \left(\frac{\partial E}{\partial w^{(2)}} \right)^{(t)}, \quad b^{(2)(t+1)} = b^{(2)(t)} - \eta \left(\frac{\partial E}{\partial b^{(2)}} \right)^{(t)}$$

$$w^{(3)(t+1)} = w^{(3)(t)} - \eta \left(\frac{\partial E}{\partial w^{(3)}} \right)^{(t)}, \quad b^{(3)(t+1)} = b^{(3)(t)} - \eta \left(\frac{\partial E}{\partial b^{(3)}} \right)^{(t)}$$

$$w^{(4)(t+1)} = w^{(4)(t)} - \eta \left(\frac{\partial E}{\partial w^{(4)}} \right)^{(t)}, \quad b^{(4)(t+1)} = b^{(4)(t)} - \eta \left(\frac{\partial E}{\partial b^{(4)}} \right)^{(t)}$$

سوال نهم:

الف) یک شبکه با حداقل تعداد TLU به گونه‌ای طراحی کنید که برای ورودی‌های داخل ناحیه‌های شکل زیر خروجی یک بدهد و برای خارج آن صفر. ساختار شبکه به همراه وزن‌ها و بایاس‌های آن را مشخص کنید.



ابد اعاده خطوط را متنفس سه اند را بدست می‌آوریم و سپس به بررسی این نظریه مربوطه در محدوده متنفس می‌باید با خیر می‌بردازیم:

$$\begin{cases} 1: y = x + 1 \\ 2: y = x - 1 \end{cases}$$

$$\begin{cases} 1: y = -x + 5 \\ 2: y = -x + 3 \end{cases}$$

$$\begin{cases} 1: y = -x + 1 \\ 2: y = -x - 1 \end{cases}$$

$$\begin{cases} 1: y = x + 5 \\ 2: y = x + 3 \end{cases}$$

$$\begin{cases} 1: y = -x - 3 \\ 2: y = -x - 5 \end{cases}$$

$$\begin{cases} 1: y = x - 3 \\ 2: y = x - 5 \end{cases}$$

حال شروط لازم برای قرار گیری در چهارک از ناحی را بدست می‌آوریم:

$$I: \begin{cases} y \leq x + 1 \\ y \geq x - 1 \\ y \leq -x + 5 \\ y \geq -x + 3 \end{cases}$$

$$I: \begin{cases} 3 \leq y + x \leq 5 \\ -1 \leq y - x \leq 1 \end{cases}$$





$$II: \begin{cases} y \leq -x + 1 \\ y \geq -x - 1 \\ y \leq x + 5 \\ y \geq x + 3 \end{cases} \rightarrow II: \begin{cases} -1 \leq y + x \leq 1 \\ 3 \leq y - x \leq 5 \end{cases}$$

$$III: \begin{cases} y \leq x + 1 \\ y \geq x - 1 \\ y \leq -x - 3 \\ y \geq -x - 5 \end{cases}$$


$$III: \begin{cases} -5 \leq y + x \leq -3 \\ -1 \leq y - x \leq 1 \end{cases}$$

$$IV: \begin{cases} y \leq -x + 1 \\ y \geq -x - 1 \\ y \leq x - 3 \\ y \geq x - 5 \end{cases} \rightarrow IV: \begin{cases} -1 \leq y + x \leq 1 \\ -5 \leq y - x \leq -3 \end{cases}$$


بنابران صد شرطی باید بررسی نشود اما با ۱۲ تامی باشد.



...



ب) آیا می‌توان با استفاده از شبکه طراحی شده در قسمت (الف) و صرفاً با تغییر پارامترهای آن، طبقه‌بندی برای شکل زیر بدست آوردن؟ توضیح دهید.







بهی‌سان. با این صورت عمل می‌کنیم برای هر محدوده دو باره کارهای قبلی را نیزی دهیم.

سلاً برای نجیب $\frac{1}{3}x+2$ داریم:

$$\begin{cases} 1: y = \frac{1}{3}x + 2 \\ 2: y = 3x - 6 \end{cases} \rightarrow I: \begin{cases} y \leq \frac{1}{3}x + 2 \\ y \geq 3x - 6 \\ x \geq 0 \\ y \geq 0 \end{cases}$$


حال نومن $\frac{1}{3}x+2$ مربوط به این چهار شرط را می‌سازیم:



به همین ترتیب بقیه نومن صراحتی سازیم. نیاز داریم که ۱۲ شرط را برسی کنیم (مانند نجیب قبل) هر دو نتیجه‌ی می‌توان با تصریفون معای شبکه عصبی قبلی حواں سهول ماسناسبی کرد.

ج) شبکه‌های TLU زیر را در نظر بگیرید. ابتدا مشخص کنید هر کدام از پاسخ‌ها توسط کدام شبکه تولید شده است و سپس علت را توضیح دهید. فرض کنید که هر کدام از شبکه‌ها فقط یک پاسخ را ایجاد کرده است.

در سهول صفحه بعد سه خود را که هر سهول توسط کدام شبکه عصبی ساخته شده است.



شکل I توسط سلسله عصی B ایجاد می شود زیرا در لایه اول دو نورون داریم که بر روی x_1 و x_2 threshold می باشد و در لایه دوم از خروجی آنها AND می کنیم که به مسئله مرتبط را خروجی دهد.

شکل II توسط سلسله عصی E ایجاد می شود زیرا در لایه اول سه نورون داریم که بر روی ترکیب خنثی $x_1 + x_2$ و $x_1 \cdot x_2$ threshold می باشد و در لایه دوم از خروجی آن نورون، AND می کنیم که مسئله با سه فلک مطلع مورد معتبر باشد.

شکل III توسط سلسله عصی D ایجاد می شود زیرا در لایه اول دو نورون داریم که هر یک که بر روی x_1 و x_2 threshold می باشد و در لایه دوم از خروجی آنها AND می کنیم که یک مستقل رابطه مانندی می دهد.

شکل IV توسط سلسله عصی F ایجاد می شود زیرا در لایه اول یک نورون دارد که صفت بر روی x_1 و x_2 threshold می باشد و در لایه دیگر دو نورون دیگر بر روی ترکیب خنثی $x_1 + x_2$ و $x_1 \cdot x_2$ threshold می باشد. در لایه سوم از خروجی نورون های قبلی، AND می کنیم که یک مستقل رابطه مانندی باشد.

شکل V توسط سلسله عصی A ایجاد می شود زیرا صفت یک نورون دارد که خروجی ای از x_1 و x_2 می باشد.

شکل VI توسط سلسله عصی C ایجاد می شود زیرا در لایه اول دو نورون داریم که خروجی هر کدام ترکیب خنثی ای از x_1 و x_2 می باشد و در لایه آخر اینکه در ورودی داده شده در خرودو نیم قطبی مرتبط به نورون های مخصوصی می شود.

سؤال ششم:

۶. (امتیازی- ۱۵ نمره) شبکه عصبی با معماری A را در نظر بگیرید. این شبکه معادل با تابع $F_A(x; W)$ است که در آن x ورودی و W تمام پارامترهای شبکه می‌باشد. فرض کنید تابع ReLU activation pattern این شبکه باشد. آنگاه برای شبکه مفهومی به نام activation pattern تعریف می‌کنیم. یک رشته از 0 و 1 به طول تعداد نورون‌های شبکه است. 0 بودن به معنای غیرفعال بودن نورون و 1 بودن به معنای فعال بودن است که در تابع ReLU معادل صفر یا غیرصفر بودن مقدار هر نورون است. تعداد این pattern ها را با $\mathcal{A}(F_A(x; W))$ نشان می‌دهیم.

الف) شبکه عصبی $F_A(\mathbb{R}^m; W)$ را با ReLU به عنوان تابع activation در نظر بگیرید. نشان دهید فضای ورودی با استفاده از این شبکه به polytope (اشکال هندسی با سطوح صاف) های convex تقسیم می‌شود که $F_A(\mathbb{R}^m; W)$ متناظر با یک تابع خطی در نواحی مختلف این فضا می‌باشد.

ب) معماری $A_{(n,k)}$ را در نظر بگیرید که معادل یک شبکه عصبی fully connected با n لایه با عرض k می‌باشد. ثابت کنید $\mathcal{A}(F_{A_{(n,k)}}(\mathbb{R}^m; W)) = \mathcal{O}(k^{mn})$ با در نظر گرفتن تابع ReLU به عنوان activation می‌باشد.

راهنمایی: فرض کنید k ابرصفحه در فضای \mathbb{R}^m وجود دارند که هر کدام متناظر با یک معادله به فرم $a_i^T x = b_i$ هستند. اگر تعداد نواحی تشکیل شده در فضا $r(k, m)$ باشد، خواهیم داشت:

$$r(k, m) \leq \sum_{i=1}^m \binom{k}{i}$$

با هنری با آنای علی خبار

الف) هر لایه شبکه عصبی دارای خروجی‌ای به فرم $\alpha^{(l)} = \text{ReLU}(z^{(l)})$ می‌باشد که لیسانه‌لایه‌ی باشد. همین خروجی هر لایه را بر اساس لایه قبلی عوار بی صورت $\hat{\alpha}^{(l)} = \begin{bmatrix} 1 \\ \hat{\alpha}^{(l)} \end{bmatrix} = W^{(l+1)} z^{(l)}$ فوست که حال با استناد از activation pattern می‌توان فعال بودن نورون‌های شبکه عصبی را بررسی کنیم (نیک نشان) فعال بودن یا نبودن نورون ناگرانی نداشته باشد.

$$\alpha_i^{(l)} = \text{ReLU}(z_i^{(l)}) = \begin{cases} z_i^{(l)} & \text{if } z_i^{(l)} \geq 0 \\ 0 & \text{o.w.} \end{cases} = \begin{cases} z_i^{(l)} & \text{if } s_i^{(l)} = 1 \\ 0 & \text{o.w.} \end{cases} \quad (\text{I})$$

فرض کنید حالت (status) یکی نورون حای لایه l را در $s^{(l)}$ می‌اردهم. داریم:

$$\alpha^{(l)} = \text{ReLU}(z^{(l)}) = \begin{bmatrix} \text{ReLU}(z_1^{(l)}) \\ \text{ReLU}(z_2^{(l)}) \\ \vdots \\ \text{ReLU}(z_n^{(l)}) \end{bmatrix} = \begin{bmatrix} s_1^{(l)} z_1^{(l)} \\ s_2^{(l)} z_2^{(l)} \\ \vdots \\ s_n^{(l)} z_n^{(l)} \end{bmatrix}$$

$$\hat{z}^{(l+1)} = W^{(l)} \hat{z}^{(l)} = W^{(l)} \begin{pmatrix} 1 \\ s_1^{(l)} z_1^{(l)} \\ s_2^{(l)} z_2^{(l)} \\ \vdots \\ s_n^{(l)} z_n^{(l)} \end{pmatrix} = \begin{bmatrix} 1 & & & & \\ b_i^{(l)} & w_{1i}^{(l)} & \dots & w_{ni}^{(l)} & \end{bmatrix} \begin{pmatrix} 1 \\ s_1^{(l)} z_1^{(l)} \\ s_2^{(l)} z_2^{(l)} \\ \vdots \\ s_n^{(l)} z_n^{(l)} \end{pmatrix}$$

$\boxed{\begin{bmatrix} 1 & & & & \\ b_i^{(l)} & s_1^{(l)} w_{1i}^{(l)} & \dots & s_n^{(l)} w_{ni}^{(l)} & \end{bmatrix}} \hat{z}^{(l)} = \hat{W}^{(l)} \hat{z}^{(l)}$

حال می توان به طور بازگشتی سه گرفت که:

$$\hat{z}^{(l+1)} = \hat{W}^{(l)} \hat{z}^{(l)} = \hat{W}^{(l)} \hat{W}^{(l-1)} \hat{z}^{(l-2)} = \dots = \left(\prod_{i=l}^0 W^{(i)} \right) \hat{z}^{(1)}, \hat{z}^{(1)} = \hat{W}^{(0)} \hat{x}$$

$$\hat{z}^{(l+1)} = \left(\prod_{i=l}^0 \hat{W}^{(i)} \right) \hat{x}$$

از طرفی دوینک رابطه یک بین نیز ملای وودی نهادن حاصل است که داده شده وجود دارد:

$$\begin{cases} z_i^{(l)} \geq 0 \leftrightarrow s_i^{(l)} = 1 \\ z_i^{(l)} < 0 \leftrightarrow s_i^{(l)} = 0 \end{cases}$$

بنابراین برای نهادن نیاز لازم رابطه زیر برقرار است:

$$(2s_i^{(l)} - 1) z_i^{(l)} = \begin{cases} z_i^{(l)} & \text{if } z_i^{(l)} \geq 0 \\ -z_i^{(l)} & \text{if } z_i^{(l)} < 0 \end{cases} \geq 0 \rightarrow (2s_i^{(l)} - 1) \odot z_i^{(l)} \geq 0$$

$$(2s_n^{(l+1)} - 1) \odot z^{(l+1)} \geq 0 \rightarrow (2s_n^{(l+1)} - 1) \odot \left(\prod_{i=l}^0 \hat{W}^{(i)} \right) \hat{x} \geq 0$$

این عبارت نشان دهنده یک convex polyhedron می باشد.

Definition of a convex polyhedron: $P = \bigcap_{i=1}^m \{x \in \mathbb{R}^n \mid a_i^T x \leq b_i\}$ (A polyhedron is also a polytope)

ب) دو حالت داریم:

$$I) \quad k < m: \quad r(k, m) \leq \sum_{i=0}^m \binom{k}{i} = \sum_{i=0}^k \binom{k}{i} = 2^k \leq k^k < k^m \rightarrow r(k, m) \leq O(k^m)$$

$$\text{II) } k \geq m: \quad r(k, m) \leq \sum_{i=0}^m \binom{k}{i} \leq \sum_{i=0}^k \binom{k}{i} \left(\frac{k}{m}\right)^{m-i} = \sum_{i=0}^k \binom{k}{i} \left(\frac{k}{m}\right)^m \left(\frac{k}{m}\right)^{-i} = \left(\frac{k}{m}\right)^m \sum_{i=0}^k \binom{k}{i} \left(\frac{k}{m}\right)^{-i}$$

$$= \left(\frac{k}{m}\right)^m \sum_{i=0}^k \binom{k}{i} \left(\frac{m}{k}\right)^i = \left(\frac{k}{m}\right)^m \left(1 + \frac{m}{k}\right)^k$$

Taylor: $e^{-x} = 1 - x + \frac{x^2}{2!} - \frac{x^3}{3!} + \dots \rightarrow 1 - x \leq e^{-x}$

$$\rightarrow r(k, m) \leq \left(\frac{k}{m}\right)^m \left(1 + \frac{m}{k}\right)^k \leq \left(\frac{k}{m}\right)^m e^{m/k} \leq \left(\frac{k}{m}\right)^m e^m = \left(\frac{e}{m}\right)^m k^m \leq O(k^m)$$

$$\rightarrow r(k, m) \underset{\text{II}}{\leq} O(k^m) \quad \xrightarrow{\text{(I), (II)}} r(k, m) \leq O(k^m)$$

بادیم ب نجیب الگوریتم هر لایه ℓ شلیلی مقدار (با اضافه کردن $O(k^m)$ خط) بینایی
با $O(k^{mn})$ خط اضافه می‌شود:

$$1 \xrightarrow{l=0} O(k^m) \xrightarrow{l=1} O(k^{2m}) \xrightarrow{l=2} \dots \xrightarrow{l=n} O(k^{mn})$$